

Report Esperimenti

Francesca Orrù

1 Addestramento dei modelli

In questa sezione vengono spiegate le modalità di addestramento dei modelli utilizzati per gli esperimenti, compresa la baseline utilizzata. Ognuna di queste famiglie di modelli presentava le proprie criticità riguardanti la diversità nella distribuzione, quindi ho cercato di gestirle individualmente, partendo da delle funzioni comuni ma creandone altre ad hoc in base alla famiglia.

1.1 KNN

Il problema dei KNN risiedeva nel fatto che, per la natura del modello stesso, fosse complicato addestrarne tanti mantenendo comunque un certo livello di diversità nelle previsioni. Un suggerimento è stato quello di utilizzare dei campioni di features diversi per ogni modello. A questo scopo, ho ritenuto conveniente creare direttamente una classe `knn` che funzionasse come il `KNeighborClassifier` di `scikit-learn` ma che introducesse il campionamento delle features nel `fit` e nei `predict` in maniera automatica, se definito da un parametro `features`. Questo mi ha permesso di addestrare 1000 modelli relativamente diversi (??), includendo un campionamento casuale delle features per ognuno, senza andare a modificare le misure già create affinché gestissero internamente i `predict` sui campioni.

1.2 Rule Tree

Per quanto riguarda i Rule Tree, il suggerimento è stato quello di lavorare sui base stumps che compongono l'albero. A questo scopo ho creato una funzione che, gestendo il random state, mi creasse degli alberi che, per ogni combinazione di parametri, mi creasse degli alberi i quali `split` venissero scelti randomicamente il 60% delle volte e seguendo il best split il restante 40%. Il risultato può essere visto in ??.

1.3 Regressori Logistici

Per i regressori logistici si è optato per l'introduzione di rumore randomico post fit sui vettori dei coefficienti.

1.4 Baseline

Per quanto riguarda la baseline, ho addestrato quattro modelli diversi, che possono essere ritenuti lo stato d'arte al momento per quanto riguarda la performance. Ad ogni modo, sebbene tutti abbiano ottenuto performance sopra la media, si possono definire alla pari dei migliori modelli addestrati tra i `knn`, Rule Tree e Regressori Logistici, probabilmente perché il dataframe utilizzato (`german credit`) non è poi così grande, quindi i modelli così complessi tendono comunque ad andare in overfitting se non viene applicata una regolarizzazione adeguata insieme al tuning degli altri parametri. Ciò nonostante, tendenzialmente gestiscono meglio la disparità tra classi.

Ho deciso di prendere il migliore tra i quattro in termini di f1 score, perché ho ritenuto che non fosse necessario che la baseline fosse nettamente superiore ai modelli interpretabili, essendo pertanto sufficiente un paragone tra i modelli più semplici e quelli più sofisticati. Mi sono basata sull'f1 perché, essendo le classi del df molto sbilanciate, risulta essere una metrica più affidabile dell'accuracy.

modello	accuracy	precision	recall	f1	dem parity	f1 robustness
Best f1 (RTC)	0.714286	0.517857	0.690476	0.591837	0.292063	0.926292
CatBoost	0.671429	0.469697	0.738095	0.574074	0.180952	0.944984
RandomForest	0.664286	0.460317	0.690476	0.552381	0.180952	0.941742
XGBoost	0.585714	0.404762	0.809524	0.539683	0.116279	0.969738
LGBM	0.671429	0.462963	0.595238	0.520833	0.277778	0.941518

Table 1: Paragone tra i 4 modelli da cui è stata ricavata la baseline e il migliore tra i modelli addestrati e da cui si dovrà filtrare il Rashomon Set.

2 Struttura del lavoro

L'analisi condotta in questo report è strutturata in questo modo:

- **Studio della correlazione tra metriche:** l'intento è quello di valutare quali tipi di correlazione ci siano tra le metriche calcolate per la definizione del RS e come variano queste correlazioni se valutate all'interno del RS stesso. Ci sono correlazioni particolari tra determinate metriche? Come variano se le inseriamo in un contesto che richiede una certa soglia di complessità, performance o equità dei modelli? Riusciremo ad ottenere dei modelli accurati, robusti, equi e non troppo complessi?
- **definizione Rashomon set:** determinazione e primo studio del Rashomon set, prima per ogni famiglia, poi per tutti i modelli. Lo scopo è lo studio del Rashomon Ratio al variare del livello di tolleranza, al quale si aggiunge una prima analisi delle altre metriche scalari all'interno del RS stesso, per capire come si presentano mediamente al suo interno.
- **Clustering del RS:** qua si vorrebbe provare a definire dei cluster di fairness, performance o complessità tra i modelli del RS, per capire se, per esempio, si possa individuare un cluster di modelli ben performanti con una fairness sopra la media, o con una complessità più controllata.
- **Analisi approfondita dei cluster:** qua si entra specificatamente nel contesto dell'equivalenza tra modelli. L'idea è quella di paragonare tutte le possibili coppie di modelli attraverso l'uso delle metriche di similarità e considerarne una media; stessa cosa con tutte le altre misure possibili, anche quelle non comparative. Si potrebbe inoltre considerare una coppia di modelli in particolare e farne un'analisi approfondita sfruttando tutte le metriche possibili. Il punto critico qui sarebbe la definizione di un threshold che definisca quando due modelli siano equivalenti o meno.

Considerando che l'ottenimento del RS e i successivi step per la definizione del gruppo finale di modelli da approfondire sono di per sé operazioni di model selection, tutte le analisi inerenti saranno fatte su un validation set, mentre l'analisi finale sull'equivalenza dei modelli scelti verrà fatta su un test set finale.

3 Studio correlazione e distribuzione delle metriche

In questa sezione, lo scopo è quello di valutare come le metriche calcolate sui modelli sono distribuite e correlate: questo ci permette di osservare se i modelli sono ben diversificati e come, per esempio, la complessità di un modello può influenzare la performance o la robustezza.

Le metriche in questione sono state suddivise in 5 macro-gruppi:

- **Performance:** Accuracy, Precision, Recall, f1 score;
- **Fairness:** Equalized Odds, Conditional Use Accuracy Equality, Demographic Parity, Equal Opportunity, Predictive Equality, Predictive Parity, Negative Predictive Parity;
- **Fairness Robustness:** Demographic Parity Robustness, Equal Opportunity Robustness, Predictive Equality Robustness, Predictive Parity Robustness, Negative Predictive Parity Robustness', Equalized Odds Robustness;
- **Performance Robustness:** Accuracy Robustness, Precision Robustness, Recall Robustness, f1 Robustness;
- **Complexity:** number of neighbors (KNN), Coefficients Magnitude (LR), Tree Depth (RTC), number of rules (RTC), number of nodes (RTC);

A scopo di visualizzazione, ho pensato che fosse più informativo considerare una variabile rappresentativa di ogni macro-gruppo. Per questo motivo, ho applicato una PCA (dove necessaria) per ogni gruppo e ottenuto una variabile che ne riassume la relazione. Chiaramente le analisi sui valori esatti verranno fatte considerando ogni singola metrica.

Sempre con il solo scopo di facilitare la visualizzazione, ho applicato del preprocessing alle metriche di fairness e al numero di vicini per il KNN:

- Per il numero di vicini ho calcolato il reciproco, per fare in modo che fosse direttamente proporzionale al concetto di complessità: maggiore il numero di vicini, minore il reciproco e minore la complessità;

$$KNNcomplexity = \frac{1}{n_neighbors} \quad (1)$$

- Le misure di fairness calcolate hanno generalmente un intervallo (0,1) o (-1,1): più si avvicinano allo 0, più il modello è equo. Per comodità ho deciso di sottrarre il loro valore assoluto a 1, in modo tale che la metrica rappresentativa della fairness aumentasse con l'aumentare dell'equità;

$$inverted_metric = 1 - |x| \quad (2)$$

Essendo x una delle metriche di equità all'interno del gruppo Fairness.

REMINDER: considerando che il concetto di complessità varia a seconda della famiglia di modelli, lo studio di questa viene fatto solo nelle analisi per modelli della stessa famiglia.




Figure 1: Correlazioni tra le macro-metriche calcolate sui modelli e le rispettive distribuzioni (sopra) e valori delle correlazioni (sotto), per ogni famiglia di modelli.

La **Figure 1** ci mostra come sono distribuiti i modelli per ogni coppia di metriche, con lo scopo di valutare come queste si influenzano a vicenda e ci offre un primo spunto superficiale su come possano essere distribuite le misure all'interno di ogni gruppo. Per completezza, vengono mostrate anche le matrici di correlazione per le misure, in modo tale da quantificare le relazioni osservate negli scatter plot.

Per gli RTC la situazione è molto promettente: infatti notiamo che i modelli, sebbene in alcuni casi concentrati in determinate zone, sono distribuiti lungo tutta la superficie. Questo vuol dire che, per esempio, in un RS con valori alti di performance avremo alte probabilità di trovare modelli più semplici o

più equi. Le metriche più correlate in questo caso sono la complexity e la robustezza in performance, ma anche qui, per come sono distribuiti i modelli, non sarà difficile trovare modelli sia semplici che robusti in un eventuale RS.

Per quanto riguarda i KNN, ciò che incuriosisce è la relazione tra la performance e la complessità dei modelli: la correlazione non è alta, ma dagli scatter plot si evince che, in un eventuale RS, non avremo troppe vie di mezzo sulla complessità, considerando i gap tra i valori. Per quanto riguarda la relazione tra equità e performance, possiamo notare che, per valori alti di performance, c'è un piccolo cluster poco denso di modelli con equità medio alta che potremo ritrovarci nel RS, anche se la percentuale sarà sicuramente più bassa che per i RTC.

Infine, i LR risultano essere i più problematici in termini di sparsità: ci basti guardare prima gli scatter plot e poi gli elevati livelli di correlazione per ogni combinazione di metriche. Banalmente, in un RS basato sulla performance, faremo fatica a trovare modelli semplici, equi o robusti. Allo stesso momento, un RS di modelli con performance ed equità o semplicità elevate sarà praticamente vuoto, come si evincerà nelle sezioni successive. Ciò nonostante, se guardiamo la **Figure 2** notiamo che in generale, la percentuale dei LR che si avvicina all'equità è quasi sempre più elevata delle altre famiglie, ma in un eventuale RS sulla performance verrebbero scartati.




Figure 2: Analisi delle distribuzioni delle metriche, famiglia per famiglia.

La **Figure 2** invece ci mostra un paragone delle famiglie sulle metriche calcolate. In generale, possiamo affermare che mediamente i RTC performano meglio dei KNN e LR: per valori elevati di performance, ci aspetteremo di avere una percentuale maggiore di RTC rispetto ai KNN o ai LR, che sono quelli meno presenti di tutti sopra un certo livello di performance. Al contrario però, come detto prima, i LR hanno la più alta concentrazione di modelli equi per quasi tutte le metriche di equità, mentre i RTC sembrano essere i più penalizzati sotto questo aspetto. Risulta anche, che la maggior parte dei modelli più robusti, sia per equità che per performance, siano sempre i LR.

Più in generale, possiamo vedere dai grafici di performance e fairness come i modelli fatichino a bilanciare bene le classi nelle loro previsioni mentre, dai range di robustezza abbastanza ristretti su valori medio-alti, si evince che tutti i modelli siamo abbastanza robusti sia per equità che per performance.

4 Studio del Rashomon Set

Nella costruzione dei RS, ci sono due questioni principali da affrontare: il livello di tolleranza ϵ e le metriche su cui ricavarlo.

Per ragioni riguardanti la comodità, ho ritenuto adeguato definire il primo RS basandomi solo sulla performance, scegliendo l' $f1$ perché la più veritiera in questo df, per poi proseguire nelle sezioni successive con il restringimento del set attraverso un processo di clustering sul resto delle metriche. Questa scelta è dovuta al fatto che altrimenti avremmo dovuto studiare e definire un ϵ per ogni gruppo di metriche utilizzate, se non per singola metrica, il che sarebbe stato gravoso. Ad ogni modo, è bene specificare che, volendo, il RS potrebbe essere definito rispetto a più threshold, oltre a quello sulla $f1$ ($f1 + demographic parity$ per fare un esempio).

Per quanto riguarda la definizione del livello di tolleranza, la letteratura non offre euristiche dirette su come sceglierlo, ma solitamente si aggira intorno a valori del 5%-20% massimo del valore di performance della baseline di riferimento. Pquesto probabilmente è dovuto al fatto che il suo valore dipenda anche dal contesto in cui si lavora e dal livello di rischio della performance dei modelli che si è disposti a sostenere. Personalmente, ho svolto prima uno studio della variazione del RR al variare di ϵ per capire quanto ci si dovesse spingere oltre per arrivare a un RS accettabile in termini di grandezza e di proporzioni sulle famiglie di modelli osservate (**Figure 3**). Da qui si nota come sia necessario, nel nostro caso, applicare valori di tolleranza di almeno 0.15 per poter avere una minima rappresentanza di tutte le famiglie all'interno di un RS generale scelto sull' $f1$, mentre basta uno 0.1 di tolleranza per avere un RS solo di RTC.

La **Figure 5** mostra bene questo trade-off e mi porta a voler proseguire con una tolleranza dello 0.2 per ragioni di studio, nonostante si veda che i KNN siano nettamente meno rappresentati rispetto ai RTC e LR.




Figure 3: Studio della variazione del RR rispetto all'aumento del livello di tolleranza ϵ sull'f1 score.




Figure 4: Visualizzazione del RR considerando livelli di tolleranza 0.1, 0.15 e 0.2 sull'f1. Le linee nera e rossa stabiliscono la soglia del RS.




Figure 5: Correlazioni tra le macro-metriche calcolate sui modelli del RS e le rispettive distribuzioni per ogni famiglia di modelli e per il RS totale.