

Report Esperimenti

Francesca Orrù

1 Addestramento dei modelli

In questa sezione vengono spiegate le modalità di addestramento dei modelli utilizzati per gli esperimenti, compresa la baseline utilizzata. Ognuna di queste famiglie di modelli presentava le proprie criticità riguardanti la diversità nella distribuzione, quindi ho cercato di gestirle individualmente, partendo da delle funzioni comuni ma creandone altre ad hoc in base alla famiglia.

1.1 KNN

Il problema dei KNN risiedeva nel fatto che, per la natura del modello stesso, fosse complicato addestrarne tanti mantenendo comunque un certo livello di diversità nelle previsioni. Un suggerimento è stato quello di utilizzare dei campioni di features diversi per ogni modello. A questo scopo, ho ritenuto conveniente creare direttamente una classe knn che funzionasse come il `KNeighborClassifier` di scikit-learn ma che introducesse il campionamento delle features nel fit e nei predict in maniera automatica, se definito da un parametro `features`. Questo mi ha permesso di addestrare 1000 modelli relativamente diversi (subsection 3.1), includendo un campionamento casuale delle features per ognuno, senza andare a modificare le misure già create affinché gestissero internamente i predict sui campioni.

1.2 Rule Tree

Per quanto riguarda i Rule Tree, il suggerimento è stato quello di lavorare sui base stumps che compongono l'albero. A questo scopo ho creato una funzione che, gestendo il random state, mi creasse degli alberi che, per ogni combinazione di parametri, mi creasse degli alberi i quali split venissero scelti randomicamente il 60% delle volte e seguendo il best split il restante 40%. Il risultato può essere visto in subsection 4.1.

1.3 Regressori Logistici

Per i regressori logistici si è optato per l'introduzione di rumore randomico post fit sui vettori dei coefficienti.

1.4 Baseline

Per la baseline inizialmente ho addestrato un XGBoost con grid search usando 5 fold per la cv, ma per quanto regolassi i parametri, il modello andava in overfitting oppure aveva una performance leggermente peggiore rispetto al migliore dei modelli. Per questo motivo ho deciso di utilizzare proprio la performance migliore tra i modelli come baseline, alla quale applico una soglia di tolleranza ϵ , che potrebbe variare in base alla famiglia di modelli nelle analisi intra-family. Questo approccio è stato utilizzato anche dalla Rudin in alcuni dei suoi paper.

gamma	learning rate	max depth	n estimators	reg l1	reg l2	subsample
0.6	0.3	2	25	0.1	1.0	0.5

Table 1: Miglior configurazione di parametri per la baseline.

2 Struttura del lavoro

L'analisi condotta in questo report è strutturata in questo modo:

- **distribuzione dei modelli:** lo scopo qui è capire quanto siano sparsi i modelli e vedere se sono ben diversificati. Questo lavoro viene svolto famiglia per famiglia, quindi avremo una distribuzione per i KNN, una per i RuleTree e una per i regressori logistici. Insieme alla densità viene analizzata anche la distribuzione delle metriche di accuracy ed F1.
- **definizione Rashomon set:** determinazione e primo studio del Rashomon set, prima per ogni famiglia, poi per tutti i modelli. Lo scopo è lo studio del Rashomon Ratio al variare del livello di tolleranza, al quale si aggiunge una prima analisi delle altre metriche scalari all'interno del RS stesso, per capire come si presentano mediamente al suo interno.
- **Studio della correlazione tra metriche:** l'intento è quello di valutare quali tipi di correlazione ci siano tra le metriche calcolate per la definizione del RS, sia in maniera generica che tra modelli all'interno del set stesso. Ci sono correlazioni particolari tra determinate metriche? Come variano se le inseriamo in un contesto che richiede una certa soglia di complessità, performance o equità dei modelli?
- **Clustering del RS:** qua si vorrebbe provare a definire dei cluster di fairness, performance o complessità tra i modelli del RS, per capire se, per esempio, si possa individuare un cluster di modelli ben performanti con una fairness sopra la media, o con una complessità più controllata.
- **Analisi approfondita dei cluster:** qua si entra specificatamente nel contesto dell'equivalenza tra modelli. L'idea è quella di paragonare tutte le possibili coppie di modelli attraverso l'uso delle metriche di similarità e considerarne una media; stessa cosa con tutte le altre misure possibili, anche quelle non comparative. Si potrebbe inoltre considerare una coppia di modelli in particolare e farne un'analisi approfondita sfruttando tutte le metriche possibili. Il punto critico qui sarebbe la definizione di un threshold che definisca quando due modelli siano equivalenti o meno.

3 KNN

3.1 Distribuzione dei modelli

Figure 1 rappresenta la distribuzione dei 1000 KNN addestrati e ne mostra la densità in diverse zone. La distribuzione bidimensionale è stata ottenuta appli-

cando una PaCMAP sul df delle metriche scalari calcolate e che verranno poi usate per definire il Rashomon set. Dal grafico sembra che i modelli siano ben distribuiti, con alcuni picchi di densità (circa 30) di modelli ai margini.

Dalla **Figure 2**, invece, i knn risultano essere concentrati principalmente intorno alla media, con una tendenza (meno accentuata per l'f1) a valori medio/alti di performance. Considerando i valori massimi sia dell'accuracy che dell'f1 e vedendo il gap tra i due valori, ho voluto approfondire per capire come si comportasse il KNN rispetto alle classi specifiche. Ho quindi applicato una Grid Search sia al knn creato da me, che al knn di scikit-learn, utilizzando la stessa griglia di parametri (abbastanza ampia) usata per l'addestramento dei 1000 modelli. I valori ottenuti da entrambi sono risultati coerenti con i massimi mostrati dai grafici, ma ho notato che i modelli tendono a considerare maggiormente la classe 0 rispetto alla classe 1. Questo probabilmente è dovuto al fatto che sul train set gli elementi di classe 0 (490) sono più del doppio di quelli di classe 1 (210), quindi più rappresentati.




Figure 1: La figura mostra come sono distribuiti i knn, prendendo in considerazione la PaCMAP bidimensionale del df con le metriche scalari calcolate sui modelli.




Figure 2: Distribuzioni dell'accuracy e F1 score tra i knn.

3.2 Definizione Rashomon Set

4 Rule Tree Classifier (RTC)

4.1 Distribuzione dei modelli

Guardando la Figure 3 possiamo dire che anche i 1000 RTC risultano ben diversificati, con alcune zone più dense ai margini della distribuzione.

Guardando l'accuracy e l'F1 (Figure 4), invece, possiamo affermare che i RTC performano leggermente meglio rispetto ai KNN e l'andamento delle distribuzioni è leggermente invertito: l'accuracy tende maggiormente a una distribuzione normale e vede pochi modelli con livelli massimi di accuracy; l'F1 invece tende maggiormente a valori sopra la media, coerente con l'ulteriore analisi che conferma che il RTC riesce a gestire meglio il gap rappresentativo tra le classi nel train set.




Figure 3: La figura mostra come sono distribuiti i RTC, prendendo in considerazione la PaCMAP bidimensionale del df con le metriche scalari calcolate sui modelli.




Figure 4: Distribuzioni dell'accuracy e F1 score tra i RTC.

4.2 Definizione Rashomon Set




Figure 5

Anche dalla Figure 5 possiamo notare che i valori dell'F1 per gli alberi decisionali subisce una penalizzazione dovuta alla disparità tra classi mentre, per definire un RS che fosse almeno vicino alla metà dei modelli nell'intero set, ho applicato un' ϵ del 15% sul valore della baseline.

5 Regressione Logistica (LR)

5.1 Distribuzione dei modelli

Dalla Figure 6 possiamo notare che i LR si distribuiscono in piccoli gruppi di media densità; questo è molto probabilmente dovuto alla scelta di applicare un rumore pesato anziché fisso ai coefficienti dei modelli per aumentare la diversità. Il rumore pesato rispetto ai valori assoluti dei coefficienti, infatti, nonostante il range di varianza non troppo basso (std 0.1), dovrebbe tendere a mantenere la gerarchia dei coefficienti e preservare la regolarizzazione (specialmente la Lasso). Questo vuol dire che i modelli, in generale, si comporteranno diversamente, ma entro un certo limite, potendo comunque rivelare differenze più accentuate in casi leggermente più estremi. Questo è confermato dal fatto che, per quanto si provi a modellare i parametri della PaCMAP per fare in modo che vengano colte le pattern globali tra i dati, la distribuzione continua a presentare dei gruppi diversificati, oppure un gruppo e degli outliers. Per quanto riguarda la performance (Figure 7) possiamo confermare che i LR siano in linea con le altre due famiglie di modelli. Un aspetto curioso potrebbe essere la netta divisione dei valori di accuracy, insieme alla presenza di una buona parte di modelli che hanno un'F1 molto vicino allo zero. Quest'ultimo aspetto, però, potrebbe essere dovuto a cattive combinazioni di parametri. Sappiamo anche che i LR, come i KNN, non gestiscono bene il gap rappresentativo tra classi.




Figure 6: La figura mostra come sono distribuiti i LR, prendendo in considerazione la PaCMAP bidimensionale del df con le metriche scalari calcolate sui modelli.




Figure 7: Distribuzioni dell'accuracy e F1 score tra i LR.

6 DUBBIO IMPORTANTE

Al momento io sto definendo un rashomon set e calcolando il rashomon ratio su un validation set, ma la teoria definisce il rashomon set su uno spazio di ipotesi riguardante il train set (chiamiamolo Rashomon Set empirico) e considera il rashomon ratio su altrettanto set. Al momento per me non avrebbe alcun senso definire un Rashomon set su un train, perché io non sto lavorando sulla mera convergenza dei modelli, ma sulla loro capacità di generalizzazione (anche le misure create finora sono destinate a un contesto di inferenza): il mio scopo sulla definizione del RS è fare model selection per arrivare allo studio di equivalenza. Inoltre, avendo 1000 modelli per ogni famiglia, chiaramente una parte di questi

sarà in overfitting, quindi definendo un RS sul validation verrebbero giustamente eliminati. Quindi noi al momento ci rifacciamo al concetto teorico di RS e RR definiti dalla Rudin, ma lo applichiamo a un contesto inferenziale.

Un'altra questione che mi preme al momento riguarda la definizione del RS per la model selection e il modo in cui sono stati campionati i dati. Io al momento ho una divisione in train—validation—test su cui sto lavorando, poi ho una divisione train—test che dovrò utilizzare all'interno della tesi finale. Il punto qui è che non potrei calcolarmi il RS sul test rientrando la sua definizione nella model selection.